

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH

ĐIỂM SỐ	ĐIỂM CHỮ	Cán bộ chấm thi 1 <i>(Kí, ghi rõ họ tên)</i>	Cán bộ chấm thi 2 <i>(Kí, ghi rõ họ tên)</i>

BÁO CÁO ĐỀ TÀI HỌC PHẦN
(Điền tên học phần)

KIỂM ĐỊNH ĐỘ TIN CẬY CỦA BỘ PHÁT HIỆN
BIỂN BÁO GIAO THÔNG YOLOv8 HƯỚNG-EDA

Rò rỉ dữ liệu, kích thước vật thể và khoảng cách hiệu năng đèn tín hiệu – biển báo

Ngành: Khoa học máy tính

Khóa: 36 (2025 – 2027)

Giảng viên giảng dạy: (Điền tên giảng viên)

Huỳnh Phát Lợi (KHMT836016)

Nhóm thực hiện: Đoàn Huỳnh Thanh Tú (KHMT836034)

Võ Phú Vinh (KHMT836036)

Thành phố Hồ Chí Minh, tháng 07 năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH



BÁO CÁO ĐỀ TÀI HỌC PHẦN
(Điền tên học phần)

KIỂM ĐỊNH ĐỘ TIN CẬY CỦA BỘ PHÁT HIỆN
BIỂN BÁO GIAO THÔNG YOLOv8 HƯỚNG-EDA

Rò rỉ dữ liệu, kích thước vật thể và khoảng cách hiệu năng đèn tín hiệu – biển báo

Ngành: Khoa học máy tính

Khóa: 36 (2025 – 2027)

Giảng viên giảng dạy: (Điền tên giảng viên)

Tên học viên: Huỳnh Phát Lợi; Đoàn Huỳnh Thanh Tú; Võ Phú Vinh

Mã số học viên: KHMT836016; KHMT836034; KHMT836036

Thành phố Hồ Chí Minh, tháng 07 năm 2026

LỜI CAM ĐOAN

Tôi xin cam đoan bài tiểu luận với đề tài “Kiểm định độ tin cậy của bộ phát hiện biến báo giao thông YOLOv8 hướng-EDA” là kết quả nghiên cứu và thực hiện của cá nhân tôi dưới sự hướng dẫn của giảng viên phụ trách học phần.

Các nội dung trình bày trong bài tiểu luận được tổng hợp, phân tích và diễn giải dựa trên quá trình tìm hiểu tài liệu, nghiên cứu phương pháp và thực nghiệm đánh giá. Các tài liệu, công trình nghiên cứu, dữ liệu và nguồn tham khảo được sử dụng trong bài đều được trích dẫn và ghi rõ trong phần tài liệu tham khảo.

Tôi cam đoan rằng bài tiểu luận không sao chép nguyên văn từ bất kỳ công trình nào khác. Các thực nghiệm được thực hiện trung thực, có cơ sở kiểm chứng và có thể tái lập. Mọi sai sót, nếu có, thuộc trách nhiệm của cá nhân tôi.

Thành phố Hồ Chí Minh, ngày 22 tháng 07 năm 2026

Học viên thực hiện

(Ký và ghi rõ họ tên)

**Huỳnh Phát Lợi; Đoàn Huỳnh Thanh Tú;
Võ Phú Vinh**

LỜI CẢM ƠN

Trước hết, tôi xin gửi lời cảm ơn chân thành đến (Điền tên giảng viên), giảng viên phụ trách học phần (Điền tên học phần), đã tận tình giảng dạy, định hướng và cung cấp những kiến thức nền tảng quan trọng cho đề tài này.

Những kiến thức và góp ý trong quá trình học tập đã giúp tôi có cơ sở để tiếp cận đề tài “Kiểm định độ tin cậy của bộ phát hiện biến báo giao thông YOLOv8 hướng-EDA” một cách có hệ thống hơn.

Tôi cũng xin cảm ơn TRƯỜNG ĐẠI HỌC SƯ PHẠM THÀNH PHỐ HỒ CHÍ MINH và Khoa Công nghệ Thông tin đã tạo điều kiện học tập, nghiên cứu và cung cấp môi trường học thuật thuận lợi trong quá trình thực hiện bài tiểu luận này.

Do giới hạn về thời gian, kinh nghiệm nghiên cứu và phạm vi thực hiện, bài tiểu luận khó tránh khỏi những thiếu sót. Tôi rất mong nhận được những góp ý từ giảng viên để có thể tiếp tục hoàn thiện nội dung và phát triển đề tài tốt hơn trong các nghiên cứu tiếp theo.

TÓM TẮT

Phát hiện biển báo và đèn tín hiệu giao thông là bài toán nền tảng của hệ hỗ trợ lái. Với các kiến trúc hiện đại như YOLOv8, độ chính xác trên các bộ dữ liệu chuẩn đã rất cao; khi con số tổng đã bão hoà, câu hỏi có giá trị không còn là “mô hình nào tốt hơn” mà là “con số đó có đáng tin và đồng đều không”. Đề tài thực hiện một **phân tích thứ cấp mang tính kiểm định** trên kết quả của một notebook Kaggle huấn luyện bộ phát hiện YOLOv8s trên bộ dữ liệu pkdarabi/cardetection.

Bộ dữ liệu gồm 15 lớp (2 lớp đèn tín hiệu, 12 lớp giới hạn tốc độ và lớp Stop), tổng cộng 4.969 ảnh và 6.012 đối tượng, nhãn rất sạch. Mô hình đã huấn luyện được coi là **công cụ đo cố định**: chúng tôi không huấn luyện lại mà trích toàn bộ kết quả notebook thành bảng chuẩn, rồi tính các chỉ số kiểm định và kiểm định thống kê để trả lời ba câu hỏi về độ tin cậy của $mAP@0,5 = 0,970$ được báo cáo.

Ba phát hiện chính. Thứ nhất, về **rò rỉ dữ liệu**: chính bước EDA phát hiện 202 ảnh trùng chính xác và 423 ảnh gần trùng xuyên split, nhưng quy trình chỉ loại 91 ảnh khỏi tập huấn luyện, còn tập kiểm thử dùng để chấm điểm không được khử trùng, khiến mAP có thể lạc quan. Thứ hai, về **khoảng cách đèn–biển**: hai lớp đèn tín hiệu chỉ đạt $mAP@0,5:0,95 = 0,541$ so với 0,854 của 13 lớp biển báo (chênh 0,313; kiểm định Mann–Whitney một phía cho $p = 0,0095$). Thứ ba, về nguyên nhân: độ hiếm của lớp **không** giải thích được khoảng cách này (tương quan Spearman $\rho = 0,032$, $p = 0,91$); trái lại, hai lớp có nhiều đối tượng nhất trên tập test lại rơi đúng vào nhóm kém nhất.

Kết luận, con số 0,97 vừa có thể được nâng đỡ bởi rò rỉ dữ liệu, vừa che giấu sự phân hoá lớn giữa các lớp, mà sự phân hoá đó bắt nguồn từ **loại vật thể** (đèn tín hiệu nhỏ, độ tương phản thấp, hai màu đỏ/xanh dễ nhầm) chứ không phải từ mất cân bằng lớp. Đây là góc nhìn kiểm định mà một báo cáo chỉ nêu mAP tổng sẽ bỏ sót. Đóng góp kèm theo gồm pipeline phân tích tái lập, ứng dụng web trình bày kết quả, cùng báo cáo và slide.

Từ khoá: kiểm định độ tin cậy, YOLOv8, phát hiện biển báo, rò rỉ dữ liệu, mất cân bằng lớp, mAP theo lớp, đèn tín hiệu.

DANH MỤC TỪ VIẾT TẮT

Từ viết tắt	Diễn giải
AP	Average Precision – Độ chính xác trung bình của một lớp
mAP	mean Average Precision – Trung bình AP trên các lớp (mAP@0,5 và mAP@0,5:0,95)
IoU	Intersection over Union – Tỷ lệ giao trên hợp giữa hai hộp
EDA	Exploratory Data Analysis – Phân tích khám phá dữ liệu
YOLO	You Only Look Once – Họ mô hình phát hiện đối tượng một giai đoạn
dHash	Difference Hash – Băm tri giác dùng phát hiện ảnh gần trùng
CSV	Comma-Separated Values – Định dạng dữ liệu phân tách bằng dấu phẩy
P / R	Precision / Recall – Độ chính xác / độ bao phủ

DANH MỤC BẢNG BIỂU

1.1	Hai hướng tiếp cận với một bộ phát hiện đã huấn luyện	1
3.1	Thống kê theo split	5
4.1	Trùng lặp và rò rỉ dữ liệu	7
4.2	Hiệu năng theo lớp trên tập test	8

DANH MỤC HÌNH ẢNH

4.1	Trùng lặp và rò rỉ — chỉ 91 ảnh bị loại khỏi tập huấn luyện, valid/test vẫn còn trùng	7
4.2	Hiệu năng theo lớp — hai lớp đèn (đỏ) tách hẳn khỏi 13 lớp biển báo . . .	9
4.3	Đèn tín hiệu kém hơn biển báo trên mọi chỉ số	9
4.4	Độ hiếm không giải thích được hiệu năng ($\rho \approx 0$)	10
4.5	Bối cảnh mất cân bằng (trái) và kích thước vật thể (phải)	11

MỤC LỤC

1	Giới thiệu	1
1.1	Bối cảnh và động cơ	1
1.2	Định vị đề tài — hai hướng tiếp cận	1
1.3	Câu hỏi nghiên cứu	1
1.4	Đóng góp	2
2	Cơ sở lý thuyết	3
2.1	Bài toán phát hiện đối tượng và chỉ số đánh giá	3
2.2	YOLOv8 như một công cụ đo	3
2.3	Rò rỉ dữ liệu và trùng lặp	3
2.4	Đo mất cân bằng lớp	3
2.5	Kiểm định thống kê sử dụng	3
2.6	Định nghĩa kích thước vật thể	4
3	Dữ liệu và phương pháp	5
3.1	Bộ dữ liệu pkdarabi/cardetection	5
3.1.1	Hạn chế về tính đại diện	5
3.2	Công cụ đo — YOLOv8s huấn luyện hướng-EDA	5
3.3	Phương pháp phân tích thứ cấp	6
3.4	Chỉ số và kiểm định	6
4	Kết quả kiểm định	7
4.1	Hiệu năng tổng thể	7
4.2	CH-A — Rò rỉ dữ liệu	7
4.3	CH-B — Khoảng cách đèn tín hiệu và biển báo	8
4.4	CH-C — Hiếm không đồng nghĩa với khó	10
4.5	Mất cân bằng và kích thước — bối cảnh	10
5	Tổng kết	12
5.1	Tổng hợp phát hiện	12

5.2	Khuyến nghị	12
5.3	Hạn chế	12
5.4	Sản phẩm kèm theo	13
TÀI LIỆU THAM KHẢO		14
PHỤ LỤC		17
Phụ lục A: Mã nguồn (GitHub)		17
Phụ lục B: Bộ dữ liệu		17
Phụ lục C: Hướng dẫn tái lập		17

CHƯƠNG 1 : GIỚI THIỆU

1.1 Bối cảnh và động cơ

Phát hiện biển báo và đèn tín hiệu giao thông là bài toán nền tảng của hệ hỗ trợ lái và xe tự hành. Với các kiến trúc hiện đại như YOLOv8, độ chính xác trên các bộ dữ liệu chuẩn đã rất cao: notebook nguồn của đề tài đạt $mAP@0,5 = 0,970$ trên tập kiểm thử. Khi con số tổng đã bão hoà, câu hỏi có giá trị khoa học không còn là “mô hình nào tốt hơn” mà là “con số đó có đáng tin và đồng đều không”.

1.2 Định vị đề tài — hai hướng tiếp cận

Có hai hướng tiếp cận khi làm việc với một bài toán học máy đã có kết quả tốt. Hướng *model-centric* tập trung cải tiến mô hình để đẩy chỉ số lên cao hơn. Hướng *data-centric* [1] lại xem chất lượng và cấu trúc dữ liệu là đối tượng nghiên cứu, và đặt câu hỏi về *độ tin cậy* của chính con số đã đạt được. Đề tài này đi theo hướng data-centric, như trình bày ở Bảng 1.1.

Bảng 1.1. Hai hướng tiếp cận với một bộ phát hiện đã huấn luyện

	Hướng model-centric	Hướng data-centric (đề tài này)
Câu hỏi	Mô hình nào phát hiện tốt hơn?	mAP 0,97 có đáng tin và đồng đều không?
Vai trò mô hình	Đối tượng nghiên cứu — huấn luyện, so sánh	Công cụ đo cố định — chỉ phân tích lại kết quả
Đầu ra	Bảng benchmark, mAP tổng	Bảng chứng thống kê về độ tin cậy và phân hoá lớp
Phương pháp	Thiết kế, huấn luyện mạng	Kiểm định thống kê, phân tích rò rỉ và phân hoá

Mô hình YOLOv8s đã huấn luyện được xem là công cụ đo cố định; đề tài chạy ở chế độ *results-only* — không huấn luyện lại mà phân tích lại các kết quả nó sinh ra. Trọng số YOLOv8 đã huấn luyện (`best.pt`) được đính kèm trong thư mục `models/` của đề tài để phục vụ ứng dụng demo và tái lập.

1.3 Câu hỏi nghiên cứu

CH-A. Mức độ rò rỉ dữ liệu xuyên split là bao nhiêu, và nó ảnh hưởng thế nào tới độ tin cậy của mAP?

CH-B. Hiệu năng có đồng đều giữa các lớp không? Nếu không, khoảng cách lớn nhất nằm ở đâu?

CH-C. Khoảng cách đó do độ hiếm của lớp (mất cân bằng) hay do bản chất vật thể?

1.4 Đóng góp

- Định lượng phơi nhiễm rò rỉ dữ liệu và chỉ ra khoảng trống trong quy trình khử trùng của notebook nguồn.
- Chứng minh bằng kiểm định thống kê rằng đèn tín hiệu kém hơn biển báo một cách có ý nghĩa.
- Bác bỏ giả thuyết “mất cân bằng gây ra thất bại” bằng bằng chứng tương quan, chuyển nguyên nhân sang loại vật thể.
- Cung cấp pipeline tái lập, ứng dụng web, báo cáo Word/LaTeX và slide trình bày.

CHƯƠNG 2 : CƠ SỞ LÝ THUYẾT

2.1 Bài toán phát hiện đối tượng và chỉ số đánh giá

Phát hiện đối tượng vừa định vị (bounding box) vừa phân loại vật thể. Chỉ số chuẩn là **mean Average Precision** (mAP): trung bình của Average Precision trên các lớp. Hai biến thể thường dùng là mAP@0,5 (ngưỡng IoU 0,5) và mAP@0,5:0,95 (trung bình trên 10 ngưỡng IoU từ 0,5 đến 0,95, nghiêm ngặt hơn về độ khớp hộp). Precision và Recall bổ sung góc nhìn về tỉ lệ dự đoán đúng và tỉ lệ bỏ sót.

2.2 YOLOv8 như một công cụ đo

YOLOv8 [2] là mô hình phát hiện một giai đoạn, dự đoán trực tiếp hộp và lớp trên lưới đặc trưng đa tỉ lệ. Trong đề tài này, một YOLOv8s đã huấn luyện được coi là *công cụ đo cố định*: ta không quan tâm cải tiến kiến trúc, mà dùng chính các lỗi và điểm số nó sinh ra làm dữ liệu để phân tích độ tin cậy.

2.3 Rò rỉ dữ liệu và trùng lặp

Rò rỉ dữ liệu (*data leakage*) xảy ra khi thông tin của tập kiểm thử “lọt” vào quá trình huấn luyện. Với dữ liệu ảnh cắt từ video, một dạng data leakage phổ biến là **ảnh trùng hoặc gần trùng xuất hiện ở nhiều split**. Perceptual hash (perceptual hash, ví dụ dHash) cho phép phát hiện ảnh gần trùng: hai ảnh có mã băm giống hoặc rất gần nhau về khoảng cách Hamming được coi là trùng tri giác. Nếu không loại trùng ở tập đánh giá, mô hình có thể “ghi nhớ” ảnh đã thấy lúc huấn luyện, làm mAP cao hơn hiệu năng thực.

2.4 Đo mất cân bằng lớp

Ba thước đo bổ sung cho nhau được dùng: *imbalance ratio* (tỉ số lớp nhiều nhất trên lớp ít nhất), *entropy chuẩn hoá* (bằng 1 khi phân bố đều) và *hệ số Gini* về bất bình đẳng (0 = cân bằng hoàn toàn; càng lớn càng tập trung). Cần phân biệt hệ số Gini bất bình đẳng với Gini impurity trong cây quyết định — đây là hai khái niệm khác nhau.

2.5 Kiểm định thống kê sử dụng

Kiểm định Mann–Whitney U [3] là kiểm định phi tham số so sánh phân phối của hai nhóm độc lập mà không giả định phân phối chuẩn — phù hợp khi so hiệu năng nhóm đèn (2 lớp) với nhóm biển (13 lớp). **Tương quan hạng Spearman** ρ [4] đo mức độ đơn điệu giữa hai biến; ta dùng nó để kiểm tra số lượng đối tượng của một lớp (độ hiếm) có liên hệ đơn điệu

với hiệu năng lớp đó hay không. Giá trị ρ gần 0 với p lớn nghĩa là không có tương quan.

2.6 Định nghĩa kích thước vật thể

Theo quy ước COCO [5], vật thể được xếp *small* nếu diện tích nhỏ hơn 32×32 px. Vật thể nhỏ khó phát hiện vì ít điểm ảnh mang thông tin; tỉ lệ vật thể nhỏ cao là một tín hiệu khó khăn cho detector, đặc biệt ở độ phân giải đầu vào thấp.

CHƯƠNG 3 : DỮ LIỆU VÀ PHƯƠNG PHÁP

3.1 Bộ dữ liệu pkdarabi/cardetection

Bộ dữ liệu gồm 15 lớp: hai lớp đèn tín hiệu (Green Light, Red Light), mười hai lớp biển giới hạn tốc độ và lớp Stop. Tổng cộng 4.969 ảnh và 6.012 đối tượng hợp lệ, chia sẵn thành ba tập như Bảng 3.1.

Bảng 3.1. Thống kê theo split

Split	Số ảnh	Số đối tượng	Đối tượng/ảnh (TB)	Diện tích bbox (px, median)
train	3.530	4.298	1,22	8.802
valid	801	944	1,18	22.928
test	638	770	1,21	8.532

Chất lượng nhãn rất sạch: 0 file nhãn thiếu, 0 đối tượng không hợp lệ, 0 dòng nhãn sai định dạng. Lớp phổ biến nhất là Red Light (787 đối tượng), hiếm nhất là Speed Limit 10 (22 đối tượng).

3.1.1 Hạn chế về tính đại diện

Dữ liệu là ảnh cắt kích thước chuẩn hoá (median 416×416), thu từ nhiều nguồn video/camera (có cả FisheyeCamera). Kết luận của đề tài giới hạn ở phạm vi bộ dữ liệu này và ở *hành vi của mô hình đã huấn luyện*, không khái quát cho mọi điều kiện đường thực tế.

3.2 Công cụ đo — YOLOv8s huấn luyện hướng-EDA

Notebook nguồn suy ra cấu hình huấn luyện từ kết quả EDA rồi huấn luyện hai giai đoạn trên GPU Tesla T4 (Ultralytics 8.4.95):

- Mô hình nền yolov8s.pt (11,13 triệu tham số, 28,5 GFLOPs); dự phòng yolov8n.pt khi thiếu bộ nhớ.
- Giai đoạn 1: imgsz=640, batch 16, tối đa 60 epoch, lr0=0,001.
- Giai đoạn 2: imgsz=768, batch 10, tối đa 35 epoch, lr0=0,0003.
- Tối ưu AdamW + cosine LR; **không** lật ngang/dọc vì lật làm sai ngữ nghĩa biển báo có hướng.

Trọng số đã huấn luyện (best .pt) được đính kèm trong thư mục `models/` của đề tài, phục vụ ứng dụng demo và việc kiểm chứng.

3.3 Phương pháp phân tích thứ cấp

Quy trình gồm ba bước, đều tự động và tái lập:

1. **Trích xuất** (`src/extract_notebook_results.py`): đọc lại toàn bộ con số đã in trong notebook, cố định thành các bảng CSV chuẩn trong `results/tables/`. Không có giá trị nào nhập tay.
2. **Kiểm định** (`src/audit_analysis.py`): tính phối ngẫu nhiên rõ ràng, khoảng cách đèn–biển (Mann–Whitney), và tương quan độ hiếm–hiệu năng (Spearman).
3. **Trực quan hoá** (`src/make_figures.py`): sinh hình từ bảng đã trích.

3.4 Chỉ số và kiểm định

Hiệu năng đo bằng Precision, Recall, mAP@0,5 và mAP@0,5:0,95 (theo Ultralytics). Khoảng cách giữa hai nhóm lớp kiểm định bằng Mann–Whitney U một phía; liên hệ độ hiếm–hiệu năng đo bằng tương quan Spearman. Mọi bước cố định hạt giống `seed=42`.

CHƯƠNG 4 : KẾT QUẢ KIỂM ĐỊNH

4.1 Hiệu năng tổng thể


Trên tập test (638 ảnh, 770 đối tượng): Precision = 0,960, Recall = 0,951, mAP@0,5 = 0,970, mAP@0,5:0,95 = 0,812. Trên tập valid, mAP@0,5 = 0,976. Nhìn tổng thể đây là kết quả rất tốt — nhưng con số tổng che giấu ba vấn đề mà ba mục sau đây làm rõ.

4.2 CH-A — Rò rỉ dữ liệu

Chính bước EDA của notebook đã phát hiện trùng lặp bằng perceptual hash và so khớp chính xác. Tuy nhiên quy trình chỉ loại trùng khỏi tập huấn luyện, còn tập kiểm thử — vốn dùng để chấm điểm — không được khử trùng (Bảng 4.1, Hình 4.1).

Bảng 4.1. Trùng lặp và rò rỉ dữ liệu

Loại trùng lặp	Số dòng ảnh	% trên tổng thể
Exact duplicate (mọi split)	460	4,63%
Exact duplicate xuyên split	202	2,03%
dHash trùng (mọi split)	799	8,04%
dHash trùng xuyên split	423	4,26%



Hình 4.1. Trùng lặp và rò rỉ — chỉ 91 ảnh bị loại khỏi tập huấn luyện, valid/test vẫn còn trùng


Nhận xét CH-A. Notebook chỉ loại 91 ảnh exact-cross-split khỏi tập huấn luyện (3.530 → 3.439). Vẫn còn 202 ảnh trùng chính xác và 423 ảnh gần trùng xuyên split không bị loại ở tập valid/test. Hệ quả: một phần điểm mAP 0,97 có thể đến từ việc mô hình đã “thấy” ảnh rất giống lúc huấn luyện — con số thực có thể thấp hơn.

4.3 CH-B — Khoảng cách đèn tín hiệu và biển báo


Bảng 4.2 trình bày hiệu năng theo từng lớp, sắp xếp giảm dần theo mAP@0,5:0,95.

Bảng 4.2. Hiệu năng theo lớp trên tập test

Lớp	Nhóm	Inst.	P	R	mAP@.5	mAP@.5:95
Stop	Biển báo	50	0,999	1,000	0,995	0,899
Speed Limit 80	Biển báo	61	0,977	1,000	0,995	0,878
Speed Limit 100	Biển báo	46	0,968	1,000	0,994	0,871
Speed Limit 70	Biển báo	53	0,922	0,943	0,973	0,867
Speed Limit 20	Biển báo	46	0,972	0,978	0,973	0,866
Speed Limit 120	Biển báo	44	0,930	1,000	0,985	0,863
Speed Limit 30	Biển báo	60	0,983	0,966	0,984	0,860
Speed Limit 60	Biển báo	45	1,000	0,933	0,992	0,859
Speed Limit 50	Biển báo	50	0,928	0,960	0,987	0,856
Speed Limit 40	Biển báo	53	0,977	0,962	0,982	0,838
Speed Limit 10	Biển báo	3	1,000	0,971	0,995	0,830
Speed Limit 90	Biển báo	34	0,995	0,971	0,993	0,827
Speed Limit 110	Biển báo	21	0,906	0,905	0,930	0,784
Green Light	Đèn	110	0,962	0,921	0,950	0,576
Red Light	Đèn	94	0,887	0,755	0,825	0,506



Hình 4.2. Hiệu năng theo lớp — hai lớp đèn (đỏ) tách hẳn khỏi 13 lớp biển báo




Hình 4.3. Đèn tín hiệu kém hơn biển báo trên mọi chỉ số

Nhận xét CH-B. Trung bình mAP@0,5:0,95: đèn tín hiệu 0,541 so với biển báo 0,854 — chênh 0,313. Kiểm định Mann–Whitney một phía cho $p = 0,0095$: khác biệt có ý nghĩa dù chỉ có 2 lớp đèn. Red Light là lớp kém nhất (mAP@0,5:0,95 = 0,506; recall chỉ 0,755).

4.4 CH-C — Hiếm không đồng nghĩa với khó

Một giả thuyết tự nhiên là “đèn kém vì hiếm”. Bằng chứng bác bỏ điều này: tương quan Spearman giữa số đối tượng trên test và $\text{mAP}@0,5:0,95$ là $\rho = 0,032$ ($p = 0,91$) — gần như bằng 0 (Hình 4.4). Ngược lại, hai lớp có *nhiều* đối tượng nhất trên tập test (Green Light 110 và Red Light 94 đối tượng) lại rơi đúng vào nhóm kém nhất.




Hình 4.4. Độ hiếm không giải thích được hiệu năng ($\rho \approx 0$)


Nhận xét CH-C. Độ hiếm của lớp không dự báo được hiệu năng — mất cân bằng không phải nguyên nhân. Nguyên nhân nằm ở bản chất vật thể: đèn tín hiệu thường nhỏ, độ tương phản thấp, và hai màu đỏ/xanh dễ nhầm về hình học. Bối cảnh kích thước: 36,6% đối tượng là “nhỏ” ($< 1\%$ diện tích ảnh) và 18,7% là “tí hon” ($< 0,1\%$).

4.5 Mất cân bằng và kích thước — bối cảnh

Toàn corpus có tỉ số mất cân bằng 35,8, entropy chuẩn hoá 0,953 và hệ số Gini 0,247 — mất cân bằng mức trung bình (Hình 4.5a). Độ dịch phân phối giữa các split rất nhỏ (Jensen–Shannon $\leq 0,008$ bit), nên chênh lệch hiệu năng không đến từ việc phân phối lớp khác nhau giữa các tập. Về kích thước, tăng độ phân giải đầu vào làm giảm mạnh tỉ lệ vật thể tí hon (Hình 4.5b) — cơ sở cho khuyến nghị tăng `imgsz` ở Chương 5.



(a) Mất cân bằng lớp



(b) Vật thể nhỏ theo độ phân giải

Hình 4.5. Bối cảnh mất cân bằng (trái) và kích thước vật thể (phải)

CHƯƠNG 5 : TỔNG KẾT

5.1 Tổng hợp phát hiện

Cả ba câu hỏi kiểm định đều chỉ về một hướng: con số mAP 0,97 cần được nhìn thận trọng hơn. Nó có thể được data leakage nâng đỡ (CH-A), đồng thời che lấp chênh lệch lớn giữa các lớp (CH-B), và chênh lệch đó bắt nguồn từ loại vật thể chứ không phải mất cân bằng (CH-C).

- **CH-A — Rò rỉ:** 202 ảnh trùng chính xác và 423 ảnh gần trùng xuyên split chưa được khử ở tập đánh giá.
- **CH-B — Khoảng cách:** đèn 0,541 so với biển 0,854 (chênh 0,313; $p = 0,0095$).
- **CH-C — Nguyên nhân:** độ hiếm không liên quan ($\rho = 0,032$); lỗi tập trung ở đèn tín hiệu.

5.2 Khuyến nghị

- Khử trùng lặp xuyên split ở *cả* tập valid/test trước khi báo cáo mAP; báo cáo thêm mAP sau khi loại near-duplicate để thấy mức chênh.
- Báo cáo AP theo từng lớp và theo nhóm (đèn/biển) thay vì chỉ mAP tổng, để không che giấu điểm yếu.
- Cải thiện lớp đèn tín hiệu: tăng độ phân giải đầu vào (imgsz 896/1024), bổ sung mẫu đèn khó, và phân tích ma trận nhầm lẫn đỏ↔xanh.
- Không dựa vào oversampling lớp hiếm để sửa lỗi đèn, vì độ hiếm không phải nguyên nhân.

5.3 Hạn chế

Đề tài ở chế độ *results-only* nên không chạy lại mô hình sau khi khử rò rỉ để đo trực tiếp mức sụt mAP; kết luận về ảnh hưởng của rò rỉ mang tính định lượng phơi nhiễm, không phải đo can thiệp. Nhóm đèn chỉ có hai lớp nên kiểm định thống kê tuy có ý nghĩa vẫn cần thận trọng khi khái quát.

5.4 Sản phẩm kèm theo

- Pipeline phân tích tái lập (`src/`) kèm kiểm thử tự động (`pytest`, 6/6 đạt).
- Ứng dụng web Streamlit (`app/app.py`) trình bày toàn bộ phân tích.
- Báo cáo Word (`.docx`), báo cáo LaTeX (mẫu trường) và slide trình bày.

TÀI LIỆU THAM KHẢO

- [1] A. Ng, “A chat with andrew on MLOps: From model-centric to data-centric AI.” DeepLearning.AI, 2021.
- [2] G. Jocher, A. Chaurasia, and J. Qiu, “Ultralytics YOLOv8.” <https://github.com/ultralytics/ultralytics>, 2023. Phiên bản 8.4.95.
- [3] H. B. Mann and D. R. Whitney, “On a test of whether one of two random variables is stochastically larger than the other,” *The Annals of Mathematical Statistics*, vol. 18, no. 1, pp. 50–60, 1947.
- [4] C. Spearman, “The proof and measurement of association between two things,” *The American Journal of Psychology*, vol. 15, no. 1, pp. 72–101, 1904.
- [5] T.-Y. Lin, M. Maire, S. Belongie, J. Hays, P. Perona, D. Ramanan, P. Dollár, and C. L. Zitnick, “Microsoft COCO: Common objects in context,” in *European Conference on Computer Vision (ECCV)*, pp. 740–755, 2014.
- [6] J. Redmon, S. Divvala, R. Girshick, and A. Farhadi, “You only look once: Unified, real-time object detection,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 779–788, 2016.
- [7] J. Redmon and A. Farhadi, “YOLO9000: Better, faster, stronger,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 7263–7271, 2017.
- [8] J. Redmon and A. Farhadi, “YOLOv3: An incremental improvement,” *arXiv preprint arXiv:1804.02767*, 2018.
- [9] A. Bochkovskiy, C.-Y. Wang, and H.-Y. M. Liao, “YOLOv4: Optimal speed and accuracy of object detection,” *arXiv preprint arXiv:2004.10934*, 2020.
- [10] S. Ren, K. He, R. Girshick, and J. Sun, “Faster R-CNN: Towards real-time object detection with region proposal networks,” in *Advances in Neural Information Processing Systems (NeurIPS)*, 2015.

- [11] W. Liu, D. Anguelov, D. Erhan, C. Szegedy, S. Reed, C.-Y. Fu, and A. C. Berg, “SSD: Single shot multibox detector,” in *European Conference on Computer Vision (ECCV)*, pp. 21–37, 2016.
- [12] T.-Y. Lin, P. Goyal, R. Girshick, K. He, and P. Dollár, “Focal loss for dense object detection,” in *IEEE International Conference on Computer Vision (ICCV)*, pp. 2980–2988, 2017.
- [13] K. He, X. Zhang, S. Ren, and J. Sun, “Deep residual learning for image recognition,” in *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, 2016.
- [14] M. Everingham, L. Van Gool, C. K. I. Williams, J. Winn, and A. Zisserman, “The PASCAL visual object classes (VOC) challenge,” *International Journal of Computer Vision*, vol. 88, no. 2, pp. 303–338, 2010.
- [15] R. Padilla, W. L. Passos, T. L. B. Dias, S. L. Netto, and E. A. B. da Silva, “A comparative analysis of object detection metrics with a companion open-source toolkit,” *Electronics*, vol. 10, no. 3, p. 279, 2021.
- [16] J. Stallkamp, M. Schlipsing, J. Salmen, and C. Igel, “The German traffic sign recognition benchmark: A multi-class classification competition,” in *International Joint Conference on Neural Networks (IJCNN)*, pp. 1453–1460, 2011.
- [17] S. Houben, J. Stallkamp, J. Salmen, M. Schlipsing, and C. Igel, “Detection of traffic signs in real-world images: The German traffic sign detection benchmark,” in *International Joint Conference on Neural Networks (IJCNN)*, 2013.
- [18] pkdarabi, “Car detection / traffic signs dataset.” <https://www.kaggle.com/datasets/pkdarabi/cardetection>, 2023.
- [19] tudeptraine, “traffic-yolo-v2-run — kaggle notebook.” <https://www.kaggle.com/code/tudeptraine/traffic-yolo-v2-run>, 2026.
- [20] C. G. Northcutt, A. Athalye, and J. Mueller, “Pervasive label errors in test sets destabilize machine learning benchmarks,” in *NeurIPS Datasets and Benchmarks Track*, 2021.

- [21] S. Kaufman, S. Rosset, C. Perlich, and O. Stitelman, “Leakage in data mining: Formulation, detection, and avoidance,” *ACM Transactions on Knowledge Discovery from Data (TKDD)*, vol. 6, no. 4, pp. 1–21, 2012.
- [22] B. Barz and J. Denzler, “Do we train on test data? purging CIFAR of near-duplicates,” *Journal of Imaging*, vol. 6, no. 6, p. 41, 2020.
- [23] C. Zauner, “Implementation and benchmarking of perceptual image hash functions,” tech. rep., Upper Austria University of Applied Sciences, Hagenberg, 2010.
- [24] M. Buda, A. Maki, and M. A. Mazurowski, “A systematic study of the class imbalance problem in convolutional neural networks,” *Neural Networks*, vol. 106, pp. 249–259, 2018.
- [25] J. M. Johnson and T. M. Khoshgoftaar, “Survey on deep learning with class imbalance,” *Journal of Big Data*, vol. 6, no. 1, pp. 1–54, 2019.
- [26] C. E. Shannon, “A mathematical theory of communication,” *The Bell System Technical Journal*, vol. 27, no. 3, pp. 379–423, 1948.
- [27] F. Pedregosa, G. Varoquaux, A. Gramfort, *et al.*, “Scikit-learn: Machine learning in Python,” *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.
- [28] C. R. Harris, K. J. Millman, S. J. van der Walt, *et al.*, “Array programming with NumPy,” *Nature*, vol. 585, pp. 357–362, 2020.
- [29] P. Virtanen, R. Gommers, T. E. Oliphant, *et al.*, “SciPy 1.0: Fundamental algorithms for scientific computing in Python,” *Nature Methods*, vol. 17, pp. 261–272, 2020.
- [30] J. D. Hunter, “Matplotlib: A 2d graphics environment,” *Computing in Science & Engineering*, vol. 9, no. 3, pp. 90–95, 2007.

PHỤ LỤC

Phụ lục liệt kê toàn bộ tài nguyên công khai phục vụ việc tái lập (reproducibility) kết quả đề tài. Tất cả các URL dưới đây có thể truy cập công khai tại thời điểm nộp đề tài.

Phụ lục A: Mã nguồn (GitHub)

- **Thư mục dự án:** `data-analysis/traffic-yolo-analysis/`
- **Cấu trúc thư mục quan trọng:**
 - `data/notebook/` — notebook Kaggle nguồn (`traffic-yolo-v2-run.ipynb`)
 - `src/` — mã trích xuất, phân tích kiểm định, vẽ hình
 - `results/tables/` — bảng CSV trích từ output notebook
 - `results/figs/` — hình sinh tự động
 - `app/app.py` — ứng dụng web Streamlit
 - `tests/` — kiểm thử tự động (pytest)
 - `reports/` — báo cáo Word, LaTeX và slide

Phụ lục B: Bộ dữ liệu

- **Bộ dữ liệu:** <https://www.kaggle.com/datasets/pkdarabi/cardetection>
 - Quy mô: 4.969 ảnh, 6.012 đối tượng, 15 lớp (đèn tín hiệu + biển báo).
 - Notebook nguồn: <https://www.kaggle.com/code/tudeptraine/traffic-yolo-v2->
 - Ngày truy cập: tháng 7/2026.

Phụ lục C: Hướng dẫn tái lập

```

1 # 1. Cài đặt môi trường
2 python -m venv .venv && source .venv/bin/activate
3 pip install -r requirements.txt
4
5 # 2. Chạy toàn bộ pipeline phân tích thu cap
6 #   (trích xuất -> kiểm định -> vẽ hình)
7 python -m src.run_pipeline
8
9 # 3. Kiểm thử tự động
10 pytest
11
12 # 4. Mô ứng dụng web

```

```
13 streamlit run app/app.py
```

Listing 1. Các bước tái lập kết quả

Môi trường: Python 3, các thư viện pandas, scipy, matplotlib; hạt giống ngẫu nhiên seed=42. Số liệu gốc do notebook Kaggle sinh trên GPU Tesla T4 (Ultralytics 8.4.95). Phân tích thứ cấp chạy hoàn toàn trên CPU.